

SAMSUNG INNOVATION CAMPUS

ARGUS AI

Model İyileştirme ve Test Değerlendirmesi

Graf Tabanlı Finansal Suç ve Hesap Ağı İstihbaratı

Ayşe Ulaşlı · Gizem Özcan

Eylül 2026

MODEL İYİLEŞTİRME

1. Genel Bakış

Model iyileştirme aşamasında amaç yalnızca tek bir skorun yükseltilmesi değil, ciddi sınıf dengesizliği bulunan AML verisinde daha tutarlı bir sıralama elde etmek ve sınırlı analist kapasitesi altında daha fazla şüpheli işlemi önceliklendirebilmektir. İlk model karşılaştırmalarından sonra LightGBM üzerinde ilerlenmiş; zamansal doğrulama, eşik seçimi, özellik ailelerinin ayrı ayrı incelenmesi ve graf tabanlı değişkenlerin eklenmesiyle model kademeli olarak iyileştirilmiştir.

2. İlk Model Değerlendirmesi

İlk aşamada Logistic Regression, Random Forest ve LightGBM aynı kronolojik eğitim-doğrulama düzeninde karşılaştırıldı. Veride pozitif sınıf oranı yaklaşık binde bir seviyesinde olduğu için accuracy ana karar ölçütü olarak kullanılmadı; model seçimi öncelikle PR-AUC üzerinden yapıldı. İlk karşılaştırmada Random Forest en yüksek doğrulama PR-AUC değerini verdi ve başlangıç referansı olarak öne çıktı.

Model	Validation PR-AUC	Recall (0,5 eşik)	FPR	Alarm sayısı
Logistic Regression	0,0066	0,962	0,1945	148.755
Random Forest	0,0886	0,722	0,0223	17.553
LightGBM	0,0055	0,874	0,1711	130.832

Bu sonuçlar aynı zamanda yalnızca varsayılan model ayarlarına güvenmenin yeterli olmadığını gösterdi. Logistic Regression tarafında yakınsama sorunu, LightGBM tarafında ise çok sayıda gözlemin aynı uç skora yığılması gibi problemler tespit edildi. Refinement aşamasında bu iki sorun ayrıca ele alındı.

3. Uygulanan İyileştirme Teknikleri

- Logistic Regression için iterasyon sınırı ve düzenleme ayarları gözden geçirilerek yakınsama sorunu giderildi.
- LightGBM için sınıf dengesizliği, ağaç karmaşıklığı ve öğrenme davranışını etkileyen parametreler validation odaklı olarak yeniden ayarlandı.
- Sabit 0,5 eşik yerine, validation verisinde alarm bütçesi ve yanlış pozitif oranı birlikte dikkate alınarak operasyonel eşik analizi yapıldı.
- İşlem değişkenleri, zamansal/geçmiş değişkenler ve graf değişkenleri ayrı özellik aileleri olarak karşılaştırıldı.
- Model seçimi sırasında final test seti kapalı tutuldu; tüm refinement kararları eğitim ve validation verisi üzerinden alındı.

4. Hiperparametre Ayarlama

Hiperparametre ayarlaması geniş ve maliyetli bir arama yerine, önceki denemelerde görülen sorunlara odaklanan kontrollü bir iyileştirme süreci olarak yürütüldü. Logistic Regression için yakınsama tamamlanacak şekilde iterasyon/çözücü ayarları düzeltildi. LightGBM tarafında ise model karmaşıklığı, sınıf dengesizliği ve skor dağılımı izlenerek daha kararlı bir yapı seçildi.

Parametre deęişiklikleri yalnızca validation ve zamansal doęrulama sonuçlarıyla deęerlendirildi; final test sonucu görölmeden önce model konfigürasyonu donduruldu.

5. Çapraz Doęrulama

Finansal işlemlerde gelecek döneme ait bilginin geçmişe sızması ciddi bir risk olduęu için rastgele K-Fold kullanılmadı. Bunun yerine zaman sırasını koruyan bloklu/zamansal doęrulama yaklaşımı kullanıldı. Bu kontrol, tek bir validation penceresindeki başarının tesadüfi olup olmadığını görmek için önemliydi. Zamansal doęrulama ortalamalarında LightGBM dięer iki temel modele göre daha güçlü bir ayırım sağladı.

Model	Zamansal CV PR-AUC
Logistic Regression	0,0288
Random Forest	0,0741
LightGBM	0,2362

6. Özellik Seçimi ve Ablation Analizi

Klasik anlamda tek tek deęişken elemek yerine, özellik ailelerinin katkısı ölçüldü. Bu yaklaşım ARGUS için daha anlamlıydı; çünkü araştırma sorusu özellikle zamansal geçmiş ve graf bilgisinin işlem bazlı modele ne kattığını ölçmekti.

Özellik seti	Validation PR-AUC
Yalnız işlem özellikleri	0,0998
İşlem + zamansal/geçmiş özellikler	0,3554
İşlem + zamansal/geçmiş + graf özellikleri	0,4718

En belirgin artış zamansal/geçmiş deęişkenlerin eklenmesiyle geldi. Graf özelliklerinin eklenmesi ise PR-AUC deęerini 0,3554'ten 0,4718'e çıkararak ARGUS'un temel araştırma sorusuna doğrudan kanıt sağladı. Yaklaşık 5.000 alarm bütçesinde recall deęeri refined LightGBM'de yaklaşık %66,8 iken graph-enhanced LightGBM'de yaklaşık %76,4'e yükseldi.

7. Model İyileştirme Kod Akışının Özeti

Repository'deki uygulama akışının sadeleştirilmiş karşılığı aşağıdaki gibidir:

```
# kronolojik veri ayrımı ve validation odaklı model seçimi
train, valid, test = chronological_split(transactions)

X_train = build_strictly_prior_features(train)
X_valid = transform_with_train_state(valid)

model = train_lightgbm(X_train, y_train, config=refined_config)
valid_scores = model.predict_proba(X_valid)[:, 1]

metrics = evaluate_ranking(y_valid, valid_scores)
threshold = select_threshold_on_validation(metrics, alert_budget=5000)

# final test bu kararlar dondurulduktan sonra yalnızca bir kez açıldı
```

TEST DEĞERLENDİRMESİ

1. Genel Bakış

Final değerlendirmede test seti model seçimi ve tuning sürecinden tamamen ayrı tutuldu. Validation sonucuna göre seçilen graph-enhanced LightGBM, final model olarak dondurulduktan sonra test seti yalnızca bir kez açıldı. Test sonuçları görüldükten sonra hiperparametre, özellik seti veya karar eşiği değiştirilmedi.

2. Test Verisinin Hazırlanması

HI-Small verisi zaman damgasına göre kronolojik eğitim, validation ve test bloklarına ayrıldı. Test verisindeki her geçmiş-temelli özellik yalnızca ilgili işlemten önce gerçekleşmiş olaylardan hesaplandı. Eğitimde öğrenilen dönüşümler ve kategorik eşlemeler test verisine aynen uygulandı; test verisinin istatistikleri eğitim dönüşümlerini yeniden fit etmek için kullanılmadı. Bu yapı özellikle veri sızıntısını önlemek için otomatik testlerle kontrol edildi.

3. Modelin Test Verisine Uygulanması

Dondurulmuş graph-enhanced LightGBM modeli test işlemlerini skorladı. Modelin görevi otomatik yaptırım vermek değil, inceleme önceliği oluşturmaktır. Bu nedenle sonuçlar hem genel sınıflandırma metrikleriyle hem de analistin inceleyebileceği üst sıralardaki vakaların kalitesini gösteren Top-K ölçütleriyle değerlendirildi.

```
test_scores = frozen_graph_lgbm.predict_proba(X_test)[: , 1]

test_metrics = {
    'pr_auc': average_precision_score(y_test, test_scores),
    'roc_auc': roc_auc_score(y_test, test_scores),
    'precision_at_100': precision_at_k(y_test, test_scores, 100),
    'precision_at_500': precision_at_k(y_test, test_scores, 500),
    'precision_at_1000': precision_at_k(y_test, test_scores, 1000),
}

save_final_artifacts(test_metrics)
```

4. Test Metrikleri

Final testte graph-enhanced LightGBM, validation aşamasında görülen üstünlüğünü korudu. Test dönemindeki pozitif sınıf oranı validation döneminden daha yüksek olduğu için precision ve alarm sayısı yorumlanırken bu dağılım farkı ayrıca dikkate alındı.

Metrik	Final test sonucu
PR-AUC	0,6901
ROC-AUC	0,9913
Precision	0,1782
Recall	0,8821
F1	0,2964
False Positive Rate	0,00836
Alarm sayısı	7.729
Precision@100	0,980

Precision@500	0,968
Precision@1000	0,839

Final model karşılaştırması:

Model	Final test PR-AUC	Yorum
Refined transaction LightGBM	0,5308	Güçlü işlem/zaman referansı
Graph-enhanced LightGBM	0,6901	Dondurulmuş final model
Sampled GraphSAGE	0,0134	Bu kurulumda graph-enhanced tree modelini geçemedi

Train metrikleri nihai model kararının ana ölçütü olarak kullanılmadığı için bu raporda karşılaştırma validation ve untouched test sonuçlarına odaklanmaktadır. Model seçimi validation üzerinde tamamlanmış, test yalnızca final değerlendirme için kullanılmıştır.

5. Modelin Uygulamaya Alınması

Model üretim ortamındaki gerçek bir banka sistemine deploy edilmedi. Bunun yerine çalışan bir Streamlit analist prototipine entegre edildi. Prototipte inceleme kuyruğu, vaka/ağ görünümü, gözlenen kanıtlar ve model açıklamaları yer alıyor. Şu aşamada ürün arayüzünün UX/UI ve pazarlama tarafındaki son düzenlemeleri devam ediyor. Bu nedenle çalışma, üretim sistemi değil çalışan bir capstone prototipi olarak değerlendirilmelidir.

6. Kod Uygulaması ve Doğrulama

Veri hazırlama, modelleme, refinement, graf özellikleri, final değerlendirme ve arayüz kodları GitHub repository'sinde modüler bir yapı altında tutulmaktadır. Final teknik kontrolde 377 otomatik test başarıyla geçti; lint ve bağımlılık kontrolleri de tamamlandı. Raw IBM verisi ve büyük üretilmiş artifact'lar repository'ye dahil edilmemektedir.

- Kronolojik split ve future-leakage kontrolleri
- Transaction, temporal/history ve graph feature testleri
- Model/evaluation artifact bütünlük kontrolleri
- Streamlit ekranları için smoke testler

Sonuç

Model iyileştirme sürecinde en önemli sonuç, performans artışının yalnız hiperparametre ayarından değil, doğru bilgi yapısının modele eklenmesinden gelmesi oldu. Transaction-only yapıdan zamansal/geçmiş özelliklere, oradan da graf özelliklerine geçildikçe PR-AUC belirgin biçimde yükseldi. Final testte graph-enhanced LightGBM 0,6901 PR-AUC ve 0,8821 recall ile dondurulmuş final model olarak doğrulandı. Sampled GraphSAGE deneyi daha karmaşık bir graf modelinin otomatik olarak daha iyi sonuç vermediğini gösterdi. Bu nedenle ARGUS'un final teknik yaklaşımı, yönlü finansal ağdan çıkarılan açıklanabilir graf sinyallerini güçlü bir LightGBM modeliyle birleştirmek ve sonucu insan onaylı bir inceleme akışına taşımak üzerine kurulmuştur.

Kaynaklar

- Altman, E. ve diğerleri (2023). Realistic Synthetic Financial Transactions for Anti-Money Laundering Models. NeurIPS Datasets and Benchmarks.

- IBM Research. AML-Data: Synthetic financial transactions for anti-money laundering research.
- Saito, T. & Rehmsmeier, M. (2015). The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets. PLOS ONE.
- Hamilton, W. L., Ying, R. & Leskovec, J. (2017). Inductive Representation Learning on Large Graphs. NeurIPS.
- Lundberg, S. M. & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. NeurIPS.
- LightGBM documentation and project repository.